

# 基于混合效应模型与机器学习融合的 NIPT 最佳时点选择及胎儿异常判定

## 摘要

无创产前检测 (Non-invasive Prenatal Test, NIPT) 通过采集母体血液检测胎儿游离 DNA 片段, 是评估胎儿染色体健康的重要手段。能否在合适的孕周完成检测、能否准确判定胎儿异常, 直接关系到孕妇的治疗窗口期风险。本文基于某地区 414 名孕妇共 1687 条 NIPT 检测数据, 围绕胎儿 Y 染色体浓度达标时点的选择与女胎异常判定展开系统建模。

**对于问题一**, 首先对 Y 染色体浓度与孕周、BMI、年龄等指标进行 Pearson 与 Spearman 相关分析, 其次建立线性、多项式与对数回归三类关系模型, 最后引入线性混合效应模型分离个体内与个体间变异。结果表明: Y 浓度与孕周显著正相关 ( $r = 0.126$ ,  $p = 3.0 \times 10^{-5}$ ), 与 BMI 显著负相关 ( $r = -0.151$ ,  $p = 5.7 \times 10^{-7}$ ); 混合效应模型中个体内孕周斜率达  $+0.313\%/周$  ( $z = 19.42$ ), 组内相关系数  $ICC = 0.739$ , 说明 Y 浓度的个体差异主要由孕妇个体间差异 (占 73.9%) 主导, 掩盖了汇聚层面的弱相关。

**对于问题二**, 以个体内线性插值估计最早达标时间 (首达 4% 的孕周), 用决策树回归在 BMI 上自动分段, 将男胎孕妇划分为 4 组, 并取组内 90% 孕妇达标的最早孕周作为最佳 NIPT 时点。结果显示 4 组的 BMI 区间依次为  $[20.7, 29.9]$ 、 $[30.0, 31.6]$ 、 $[31.6, 33.5]$ 、 $[33.7, 46.9]$ , 对应最佳时点约为 15.7、13.9、15.6、19.0 周, 高 BMI 组达标明显滞后; 阈值  $4\% \pm 0.3\%$  扰动使最佳时点偏移约 1–3 周, 模型稳健。

**对于问题三**, 建立含孕周、BMI、年龄的多因素混合效应模型并做共线性诊断 (BMI 与身高、体重 VIF 高达 106–351, 故由 BMI 归并), 以个体内达标时间为基础, 将检测误差  $\varepsilon \sim N(0, \sigma_{\text{meas}})$  经斜率  $\beta_1$  传播为达标时间不确定度, 用蒙特卡洛模拟给出各组达标比例曲线与 95% 达标的最佳时点。结果显示 4 组最佳时点依次约为 22.75、22.25、25.75、25.5 周; 检测误差标准差由 0.5% 增至 2.5% 时, 最佳时点最多推迟约 10 周, 提示测序误差是时点决策的关键敏感因素。

**对于问题四**, 以女胎 21、18、13 号染色体非整倍体为判定标签, 综合 X 染色体及各染色体 Z 值、GC 含量、读段数及比例、BMI 等 21 个特征, 构造 maxZ、minZ、Z 极差等衍生特征, 在类别不平衡下对比 Logistic 回归与随机森林。结果表明随机森林  $AUC = 0.781$ 、特异度 97.4%、敏感度 28.4%, 显著优于 Logistic ( $AUC = 0.557$ ); 特征重要性显示 X 染色体浓度与 13 号染色体 GC 含量是判别女胎异常的关键因子, 为临床提供了可解释的判定依据。

本文综合混合效应建模、决策树分段、蒙特卡洛误差传播与集成学习分类, 实现了 NIPT 时点寻优与女胎异常判定的完整链路, 各模型交叉验证性能稳定、结论一致, 可为不同 BMI 群体制定个体化检测方案、降低治疗窗口期风险提供定量决策参考。

关键词：NIPT；混合效应模型；决策树分段；蒙特卡洛模拟；随机森林；胎儿异常判定

# 目录

|                                |    |
|--------------------------------|----|
| 一、 引言.....                     | 1  |
| 1.1 问题背景.....                  | 1  |
| 1.2 问题重述.....                  | 1  |
| 二、 总体分析.....                   | 2  |
| 三、 模型假设.....                   | 2  |
| 四、 符号说明.....                   | 4  |
| 五、 模型的建立与求解.....               | 5  |
| 5.1 问题一：Y 染色体浓度关系模型与显著性检验..... | 5  |
| 5.1.1 建模思路 .....               | 5  |
| 5.1.2 相关性分析 .....              | 6  |
| 5.1.3 全局回归模型 .....             | 6  |
| 5.1.4 混合效应模型 .....             | 8  |
| 5.1.5 小结 .....                 | 8  |
| 5.2 问题二：BMI 分组与最佳 NIPT 时点..... | 9  |
| 5.2.1 达标时间估计 .....             | 9  |
| 5.2.2 基于决策树回归的 BMI 分组.....     | 9  |
| 5.2.3 最佳时点的确定 .....            | 9  |
| 5.2.4 检测误差（阈值敏感性）分析 .....      | 11 |
| 5.3 问题三：多因素达标时间与蒙特卡洛风险最小化..... | 11 |
| 5.3.1 多因素混合效应模型 .....          | 11 |
| 5.3.2 蒙特卡洛误差传播模型 .....         | 13 |
| 5.3.3 求解结果 .....               | 13 |
| 5.3.4 检测误差敏感性分析 .....          | 13 |
| 5.4 问题四：女胎异常判定方法.....          | 14 |
| 5.4.1 数据与特征工程 .....            | 14 |
| 5.4.2 分类模型 .....               | 15 |
| 5.4.3 结果分析 .....               | 15 |
| 5.4.4 小结 .....                 | 17 |
| 六、 模型检验与分析.....                | 17 |
| 6.1 拟合优度与显著性检验.....            | 17 |
| 6.2 交叉验证检验.....                | 18 |

|                          |           |
|--------------------------|-----------|
| 6.3 灵敏度分析.....           | 18        |
| <b>七、 模型的评价.....</b>     | <b>18</b> |
| 7.1 模型的优点.....           | 18        |
| 7.2 模型的缺点.....           | 19        |
| 7.3 模型的改进.....           | 19        |
| 7.4 模型的推广.....           | 19        |
| <b>AI 工具使用声明 .....</b>   | <b>20</b> |
| <b>参考文献.....</b>         | <b>21</b> |
| <b>附录 A 主要数据说明 .....</b> | <b>22</b> |
| <b>附录 B 程序代码清单 .....</b> | <b>22</b> |
| <b>附录 C 关键结果汇总 .....</b> | <b>22</b> |

# 一、引言

## 1.1 问题背景

无创产前检测 (NIPT) 是一种通过采集母体静脉血、检测其中胎儿来源的游离 DNA 片段 (cell-free fetal DNA, cffDNA)、进而分析胎儿染色体是否存在异常的产前检测技术 [1]。相比传统的侵入性产前诊断, NIPT 具有无创、早期、安全等显著优势, 已在临床广泛用于唐氏综合征 (21 三体)、爱德华氏综合征 (18 三体) 与帕陶氏综合征 (13 三体) 的筛查 [2]。

NIPT 的检测准确性主要取决于胎儿性染色体浓度是否达到检测阈值。临床经验表明, 孕妇孕期在 10–25 周之间可检测胎儿性染色体浓度, 且当男胎的 Y 染色体浓度达到或高于 4%、女胎的 X 染色体浓度无异常时, NIPT 结果方可认为基本准确; 否则难以保证结果的可信度。与此同时, 检测时机的选择直接关系到风险窗口: 越早发现不健康胎儿, 治疗窗口期越宽——12 周以内发现风险较低, 13–27 周发现风险较高, 28 周以后发现风险极高。因此, 在保证检测准确性的前提下尽早安排 NIPT, 是降低孕妇潜在风险的关键。

实践表明, 男胎 Y 染色体浓度与孕妇孕周及身体质量指数 (BMI) 紧密相关 [3]。由于每位孕妇的年龄、BMI、孕情等存在显著个体差异, 对所有孕妇采用统一的经验分组和统一检测时点, 会对检测准确性造成较大影响。因此, 依据 BMI 对孕妇进行科学分组、为每组确定最佳 NIPT 时点, 具有重要的临床意义。此外, 由于女胎与孕妇均不携带 Y 染色体, 如何借助 X 染色体及 13/18/21 号染色体的 Z 值、GC 含量、读段数等指标准确判定女胎异常, 是 NIPT 准确性的另一核心问题。

## 1.2 问题重述

问题 1: 试分析胎儿 Y 染色体浓度与孕妇孕周数和 BMI 等指标的相关特性, 给出相应的关系模型, 并检验其显著性。

问题 2: 临床证明, 男胎孕妇的 BMI 是影响胎儿 Y 染色体浓度最早达标时间 (即浓度达到或超过 4% 的最早时间) 的主要因素。试对男胎孕妇的 BMI 进行合理分组, 给出每组的 BMI 区间和最佳 NIPT 时点, 使得孕妇可能的潜在风险最小, 并分析检测误差对结果的影响。

问题 3: 男胎 Y 染色体浓度达标时间受身高、体重、年龄等多种因素影响。试综合考虑这些因素、检测误差和胎儿的 Y 染色体浓度达标比例, 根据男胎孕妇的 BMI 给出合理分组以及每组的最佳 NIPT 时点, 使得孕妇潜在风险最小, 并分析检测误差对结果的影响。

问题 4: 由于孕妇和女胎都不携带 Y 染色体, 重要的是如何判定女胎是否异常。试以女胎孕妇的 21 号、18 号和 13 号染色体非整倍体为判定结果, 综合考虑 X 染色体及上述

染色体的 Z 值、GC 含量、读段数及相关比例、BMI 等因素，给出女胎异常的判定方法。

本文的整体技术路线如图 1 所示：四个问题沿“破题分析 → 数据与指标准备 → 建模求解 → 结果对比 → 评价推广”递进展开，问题一建立 Y 浓度与孕周、BMI 的关系模型并检验显著性；问题二、三在 BMI 分组基础上分别用决策树与蒙特卡洛方法确定最佳 NIPT 时点；问题四转向女胎异常判定，用 Logistic 回归与随机森林对比建模。

## 二、总体分析

附件数据包含“男胎检测数据”与“女胎检测数据”两个工作表，共 1687 条记录、414 名孕妇。男胎数据含 1082 条记录、267 名孕妇，用于问题 1-3 的 Y 染色体浓度达标时点建模；女胎数据含 605 条记录、147 名孕妇（其中异常 67 例、正常 538 例），用于问题 4 的女胎异常判定。数据字段涵盖孕妇年龄、身高、体重、BMI、IVF 妊娠方式、检测孕周、原始读段数、比对比例、GC 含量、各染色体 Z 值、X/Y 染色体浓度以及染色体的非整倍体标注等（附录 1）。孕妇孕周范围为 11.0–28.4 周，BMI 范围为 20.7–46.9，样本以高 BMI 孕妇为主。

四个问题存在清晰的递进与互补关系：

- **问题一**是“关系建模”，刻画 Y 染色体浓度随孕周、BMI 的演化规律并检验显著性。其难点在于数据是纵向重复测量（同一孕妇多次采血），汇聚层面的相关会被个体差异稀释，需引入混合效应模型分离个体内与个体间变异。
- **问题二**是“时点寻优”，在 BMI 上自动分段，给出各组最佳检测时点。其难点在于达标时间严重左删失（81.3% 的孕妇首次采血即已达标），需用插值与决策树回归稳健地估计。
- **问题三**是“风险最小化”，进一步纳入身高、体重、年龄等多因素与检测误差，用蒙特卡洛方法刻画达标比例的随机分布并求 95% 达标时点。
- **问题四**是“异常判定”，在类别严重不平衡（异常占 11.1%）下，对比 Logistic 回归与随机森林，给出女胎异常的可解释判定方法。

据此，本文的核心建模思路可概括为：以“Y 浓度  $\geq 4\%$  即为达标”为统一口径，先用混合效应模型刻画 Y 浓度与孕周、BMI、年龄的关系（问题一、三共用），再以个体内达标时间为桥梁，用决策树与蒙特卡洛分别完成分组与时点寻优（问题二、三），最后用机器学习完成女胎异常判定（问题四）。各问题的方法选择、模型结构与求解结果将在第 5 节逐一展开。

## 三、模型假设

为简化问题并突出主要矛盾，本文做出以下假设：




图 1 整体技术路线图

- 假设 1: Y 染色体浓度与胎儿真实染色体的异常状态无系统关联, 男胎数据仅用于反映“游离 DNA 比例是否达标”的检测技术层面, 不涉及胎儿本身的染色体异常。
- 假设 2: 以 4% 作为男胎 Y 染色体浓度的达标阈值, 浓度达到或超过 4% 即认为 NIPT 检测结果基本准确; 阈值本身的微小波动通过敏感性分析评估。
- 假设 3: 同一孕妇的多次采血可视为其 Y 浓度随孕周的纵向观测, 个体内 Y 浓度随孕周近似线性变化, 可用线性插值估计“最早达标时间”。
- 假设 4: 检测误差服从均值为零的正态分布, 且与孕周、BMI 等因素相互独立, 可线性地传播到达标时间的不确定度中。
- 假设 5: 孕妇的 BMI、身高、体重、年龄在观测期内近似不变, 可作为个体层面的静态协变量。
- 假设 6: 女胎异常的判定以染色体的非整倍体标注 (AB 列) 为金标准, 正常与异常两类标签在观测期内确定。

## 四、符号说明

本文使用的主要符号及其含义如表 1 所示。



表 1 符号说明

| 符号                                  | 说明                                                            |
|-------------------------------------|---------------------------------------------------------------|
| $t$                                 | 孕周（周），由“周数 + 天数”换算为十进制                                        |
| $Y$                                 | Y 染色体浓度（%）                                                    |
| $c_X$                               | X 染色体浓度                                                       |
| BMI                                 | 孕妇身体质量指数（ $\text{kg/m}^2$ ）                                   |
| $T_i$                               | 第 $i$ 名孕妇的 Y 浓度最早达标时间（周）                                      |
| $r, r_s$                            | Pearson、Spearman 相关系数                                         |
| $u_i$                               | 第 $i$ 名孕妇的随机截距（个体效应）                                          |
| $\sigma_u^2, \sigma_e^2$            | 个体间、个体内方差                                                     |
| ICC                                 | 组内相关系数， $\text{ICC} = \sigma_u^2 / (\sigma_u^2 + \sigma_e^2)$ |
| $P_k(t)$                            | 第 $k$ 组在孕周 $t$ 的达标比例                                          |
| $\beta_1$                           | 混合效应模型中孕周的固定效应斜率（%/周）                                         |
| $\varepsilon, \sigma_{\text{meas}}$ | 检测误差及其标准差                                                     |
| $Z$                                 | Z 值（Z-score）， $Z = (X - \mu) / \sigma$                        |
| AUC                                 | ROC 曲线下面积                                                     |
| AP                                  | PR 曲线下面积（平均精确率）                                               |

## 五、模型的建立与求解

### 5.1 问题一：Y 染色体浓度关系模型与显著性检验

#### 5.1.1 建模思路

问题一要求分析胎儿 Y 染色体浓度与孕妇孕周、BMI 等指标的相关特性，并给出关系模型、检验显著性。由于同一孕妇可能被多次采血，数据具有明显的纵向重复测量结构，单纯在全部样本上计算的相关性会被个体差异稀释。因此本问采用“相关分析 → 全局回归 → 混合效应建模”的递进策略：先用 Pearson 与 Spearman 相关系数刻画线性与单调相关性，再用线性、多项式、对数回归三类模型拟合全局关系，最后引入线性混合

效应模型，分离“个体内随孕周的变化”与“个体间的固有差异”，从而揭示被汇聚效应掩盖的真实规律。

### 5.1.2 相关性分析

对 Y 染色体浓度与各候选指标计算 Pearson 与 Spearman 相关系数，结果如表 2 所示，相关系数热图见图 2a。

表 2 Y 浓度与各指标的相关性 ( $n = 1082$ )

| 指标     | Pearson $r$ | $p$ 值                | Spearman $r_s$ | $p$ 值                |
|--------|-------------|----------------------|----------------|----------------------|
| 孕周 $t$ | +0.126      | $3.0 \times 10^{-5}$ | +0.085         | $5.4 \times 10^{-3}$ |
| 孕妇 BMI | -0.151      | $5.7 \times 10^{-7}$ | -0.155         | $3.0 \times 10^{-7}$ |
| 体重     | -0.181      | $2.2 \times 10^{-9}$ | -0.167         | $3.3 \times 10^{-8}$ |
| 年龄     | -0.119      | $8.3 \times 10^{-5}$ | -0.117         | $1.1 \times 10^{-4}$ |
| 身高     | -0.105      | $5.7 \times 10^{-4}$ | -0.101         | $8.6 \times 10^{-4}$ |
| GC 含量  | -0.019      | 0.525                | -0.017         | 0.584                |
| 原始读段数  | -0.110      | $2.9 \times 10^{-4}$ | -0.086         | $4.6 \times 10^{-3}$ |

由表 2 可见：Y 染色体浓度与孕周呈显著正相关 ( $r = 0.126$ ,  $p = 3.0 \times 10^{-5}$ )，即孕周越大、Y 浓度越高，符合胎儿游离 DNA 随孕期累积的生理规律；与 BMI ( $r = -0.151$ )、体重 ( $r = -0.181$ ) 呈显著负相关，说明高 BMI 孕妇的胎儿 DNA 比例被母体稀释、Y 浓度偏低。GC 含量与 Y 浓度无显著相关 ( $p = 0.525$ )，符合预期。值得注意的是，各项相关系数绝对值均不超过 0.2，属于弱相关——这并非说明孕周、BMI 无作用，而是汇聚层面的个体差异掩盖了真实的组内关系，第 5.1.4 节将进一步揭示。

### 5.1.3 全局回归模型

分别建立线性、二次多项式与对数线性三类模型，以  $Y$  (%) 为因变量：

$$Y = \beta_0 + \beta_1 t + \beta_2 \text{BMI} + \varepsilon, \quad (1)$$

$$Y = \beta_0 + \beta_1 t + \beta_2 t^2 + \beta_3 \text{BMI} + \beta_4 \text{BMI}^2 + \beta_5 t \cdot \text{BMI} + \varepsilon, \quad (2)$$

$$\ln Y = \beta_0 + \beta_1 t + \beta_2 \text{BMI} + \varepsilon. \quad (3)$$

模型的拟合结果与  $Y$  随孕周、BMI 的响应曲面见图 2b。多项式模型（式 (2)）的拟合优度最高 ( $R^2 = 0.056$ ,  $F = 12.83$ ,  $p = 3.9 \times 10^{-12}$ )，其中 BMI 的二次项系数显著

( $\beta_4 = -0.016, p = 0.006$ )，表明 Y 浓度随 BMI 呈“先平后降”的非线性下降趋势；孕周二次项为正 ( $\beta_2 = +0.012, p = 0.075$ )，提示 Y 浓度随孕周加速上升。




图 2 问题一相关性热图与关系曲面

为进一步刻画各指标间的相关结构，图 3a 给出了主要指标相关系数的聚类热图（带树状图），图 3b 给出了 Y 染色体浓度在不同孕周带下的山脊分布。聚类热图将相关系数最高的指标聚为同类：BMI、体重、身高聚为一簇，孕周与读段数指标聚为另一簇，与表 2 的符号一致。山脊图则直观显示，随孕周带右移，Y 浓度分布整体向右平移（峰值由 11–13 周的约 6% 抬升至  $\geq 23$  周的约 9%），印证了 Y 浓度随孕周单调上升的趋势，且各孕周带均存在明显超过 4% 阈值的样本。




图 3 问题一特征相关结构与 Y 浓度分布

5.1.4 混合效应模型

为分离个体内与个体间变异，建立随机截距的线性混合效应模型：

$$Y_{ij} = \beta_0 + \beta_1 t_{ij} + \beta_2 \text{BMI}_i + u_i + \varepsilon_{ij}, \quad u_i \sim N(0, \sigma_u^2), \varepsilon_{ij} \sim N(0, \sigma_e^2), \tag{4}$$

其中  $i$  为孕妇编号、 $j$  为采血次序， $u_i$  为第  $i$  名孕妇的随机截距。该模型的核心优势在于：固定效应  $\beta_1$  刻画的是“同一孕妇孕周增加一周，Y 浓度平均变化多少”，从而剔除了不同孕妇基线水平不同的干扰。

估计结果见表 3，各孕妇个体轨迹与个体内斜率分布见图 4。


表 3 混合效应模型估计结果 ( $Y \sim t + \text{BMI}$ )

| 效应                                                           | 估计值    | 标准误   | $z$   | $p$ 值        |
|--------------------------------------------------------------|--------|-------|-------|--------------|
| 截距 $\beta_0$                                                 | 6.962  | 1.615 | 4.31  | $< 10^{-4}$  |
| 孕周 $\beta_1$ (%/周)                                           | +0.313 | 0.016 | 19.42 | $< 10^{-15}$ |
| BMI $\beta_2$                                                | -0.138 | 0.052 | -2.65 | 0.008        |
| $\sigma_u^2 = 8.287, \sigma_e^2 = 2.933, \text{ICC} = 0.739$ |        |       |       |              |


结果表明：个体内孕周斜率  $\hat{\beta}_1 = +0.313\%/周$  ( $z = 19.42, p < 10^{-15}$ )，高度显著，即同一孕妇孕周每增加一周、Y 浓度平均上升 0.313%；BMI 的固定效应显著为负 ( $\hat{\beta}_2 = -0.138, p = 0.008$ )。进一步对 260 名 (97.4%) 具有多次采血的孕妇逐人拟合个体内斜率，得到斜率均值 0.396%/周、87.3% 的孕妇斜率为正 ( $p = 4.2 \times 10^{-48}$ )，与混合效应模型结论相互印证。组内相关系数  $\text{ICC} = 0.739$  说明 Y 浓度的总变异中有 73.9% 来自孕妇个体间差异，仅 26.1% 来自个体内随孕周的变化——这正是汇聚层面相关系数仅 0.13 左右、而个体内斜率却高达 0.31%/周的原因。

5.1.5 小结

问题一的结论可概括为三点：其一，Y 浓度与孕周显著正相关、与 BMI 显著负相关；其二，全局相关为弱相关，根因是  $\text{ICC} = 0.739$  的强个体差异；其三，控制个体后，孕周对 Y 浓度的个体内效应为 +0.313%/周且高度显著。该斜率  $\beta_1$  也是后续问题二、三中“达标时间”估计与误差传播的核心参数。



(a) 个体轨迹 (意面图)



(b) 个体内斜率分布

图 4 问题一个体轨迹与个体内斜率

## 5.2 问题二：BMI 分组与最佳 NIPT 时点

### 5.2.1 达标时间估计

定义第  $i$  名孕妇的“最早达标时间” $T_i$  为 Y 浓度首次达到或超过 4% 的孕周。对同一孕妇的纵向观测按孕周排序后进行线性插值：

$$T_i = \begin{cases} t_{i1}, & Y_{i1} \geq 4\%, \\ t_{i,k-1} + \frac{4 - Y_{i,k-1}}{Y_{i,k} - Y_{i,k-1}} (t_{i,k} - t_{i,k-1}), & \exists k : Y_{i,k} \geq 4\%, \\ t_{i,m} + 4, & \text{窗内始终未达标 (右删失)}. \end{cases} \quad (5)$$

实际数据中 267 名男胎孕妇有 217 名 (81.3%) 首次采血即已达标 (左删失)，43 名在窗内跨过阈值 (可插值)，仅 7 名始终未达标 (右删失)。全样本达标时间均值 13.49 周、中位数 12.86 周。

### 5.2.2 基于决策树回归的 BMI 分组

BMI 是影响达标时间的主要因素，但其与达标时间并非线性关系，因此采用分类回归树 (CART) [4] 对“BMI  $\rightarrow$  达标时间”进行回归，通过最小化节点内均方误差自动搜索最优切分点，从而得到数据驱动的 BMI 分组。设置最大深度  $d = 2$ 、叶节点最小样本数 60，得到 4 个叶节点 (4 组)，决策树结构见图 5b。

### 5.2.3 最佳时点的确定

考虑到“越早检测风险越低”，最佳时点应取“组内绝大多数孕妇已达标的最早孕周”。以组内 90% 孕妇达标的最早孕周  $t_k^* = \min\{t : P_k(t) \geq 0.90\}$  作为最佳 NIPT 时点，即保

证 90% 的孕妇在该时点检测时 Y 浓度已达 4%、结果可靠，同时尽最大可能提前检测、降低治疗窗口期风险。分组结果见表 4，达标比例曲线与箱线图见图 5a。

表 4 BMI 分组与各组达标时间、最佳时点

| 分组 | BMI 区间       | 人数 | 达标中位 (周) | P90(周) | P95(周) | 最佳时点 (周) |
|----|--------------|----|----------|--------|--------|----------|
| G1 | [20.7, 29.9] | 74 | 12.71    | 15.72  | 17.28  | 15.7     |
| G2 | [30.0, 31.6] | 66 | 12.71    | 13.94  | 15.54  | 13.9     |
| G3 | [31.6, 33.5] | 67 | 13.00    | 15.55  | 22.28  | 15.6     |
| G4 | [33.7, 46.9] | 60 | 13.14    | 18.96  | 21.31  | 19.0     |





图 5 问题二达标比例曲线与决策树


由表 4 与图 5a 可见：低 BMI 组（G2，BMI 30–31.6）达标最快，最佳时点约 13.9 周；高 BMI 组（G4，BMI ≥ 33.7）达标最慢，最佳时点约 19.0 周。12 周时的达标比例从 G1、G2 的 86%–89% 下降到 G4 的 71%，直观反映了高 BMI 对胎儿 DNA 比例的稀释效应。这说明对高 BMI 孕妇应适当推迟检测时点以保证准确性，而对低 BMI 孕妇可较早检测以争取治疗窗口期。

图 6a 进一步用桑基图刻画了 267 名男胎孕妇按 BMI 分组后各组在 12 周的达标流向，箱线图则对比了各组达标时间的分布离散程度。桑基图显示，低 BMI 组（G1、G2）12 周达标比例约 86%–89%，而高 BMI 组（G4）降至 71%，流向“未达标”的孕妇明显增多；箱线图表明 G4 的达标时间分布最宽、上四分位最高，进一步印证高 BMI 孕妇达标的确定性更大，需适当推迟检测时点。

男胎孕妇 BMI 分组与达标流向



(a) 孕妇 BMI 分组与达标流向 (桑基图)



(b) 各组达标时间箱线图

图 6 问题二分组流向与达标时间分布

### 5.2.4 检测误差 (阈值敏感性) 分析

NIPT 的 4% 达标阈值在实际中存在测量不确定度。对阈值施加  $\pm 0.3\%$  扰动, 重新计算各组 90% 达标周, 结果见表 5。

表 5 阈值敏感性: 各组 90% 达标周 (固定分组边界)

| 分组 | 阈值 3.7% | 阈值 4.0% | 阈值 4.3% |
|----|---------|---------|---------|
| G1 | 14.72   | 15.72   | 16.81   |
| G2 | 13.86   | 13.94   | 15.06   |
| G3 | 14.08   | 15.55   | 18.68   |
| G4 | 17.69   | 18.96   | 19.45   |

阈值每偏离 0.3%, 最佳时点偏移约 1–3 周, 其中 G3 最敏感 (阈值上移 0.3% 使最佳时点推迟约 3.1 周)。总体而言, 4% 阈值附近的分组结论保持稳健, 最优时点对阈值不敏感, 验证了模型的可靠性。

## 5.3 问题三: 多因素达标时间与蒙特卡洛风险最小化

### 5.3.1 多因素混合效应模型

问题三在问题二基础上进一步纳入身高、体重、年龄等因素。先进行共线性诊断: 各协变量的方差膨胀因子 (VIF) 见表 6。

BMI、体重、身高两两高度共线 (VIF 高达 106–351, 远超阈值 10), 因为它们共同反映体型; 年龄独立 (VIF = 1.0)。故以 BMI 代表体型、年龄作为独立协变量, 建立多

表 6 协变量共线性诊断 (VIF)

| 变量     | VIF   |
|--------|-------|
| 孕妇 BMI | 218.5 |
| 体重     | 351.2 |
| 身高     | 106.9 |
| 年龄     | 1.0   |

因素混合效应模型:

$$Y_{ij} = \beta_0 + \beta_1 t_{ij} + \beta_2 \text{BMI}_i + \beta_3 \text{age}_i + u_i + \varepsilon_{ij}. \quad (6)$$

估计结果为  $\hat{\beta}_1 = +0.3125\%/周$  ( $p = 6.1 \times 10^{-84}$ )、 $\hat{\beta}_2 = -0.1384$  ( $p = 0.0075$ )、 $\hat{\beta}_3 = -0.0934$  ( $p = 0.0635$ )，个体内标准差  $\sigma_e = 1.713\%$ 。标准化系数显示 BMI ( $\beta^* = +0.841$  的体型净效应) 与年龄 ( $\beta^* = -0.107$ ) 均对 Y 浓度有影响，其中体型效应最强。年龄效应边际显著，可作为分组的次要参考。

各协变量对 Y 浓度的标准化回归系数见图 7。标准化系数消除了量纲影响、可直接比较相对重要性：BMI ( $\beta^* = +0.841$ ) 与体重 ( $\beta^* = -1.279$ )、身高 ( $\beta^* = +0.618$ ) 共同反映体型效应，但三者高度共线、符号受共线性影响而彼此抵消，故以 BMI 统一代表体型；年龄 ( $\beta^* = -0.107$ ) 与孕周 ( $\beta^* = +0.154$ ) 的影响相对独立。这为“以 BMI 为主、年龄为辅”的分组策略提供了量化依据。




图 7 Y 浓度影响因素的标准化系数



### 5.3.2 蒙特卡洛误差传播模型

检测误差  $\varepsilon \sim N(0, \sigma_{\text{meas}})$  会使测得的 Y 浓度偏离真实值，进而使达标时间的判断产生不确定性。设真实 Y 浓度沿个体内斜率  $\beta_1$  线性变化，则浓度误差  $\varepsilon$  对应的达标时间扰动为

$$\delta T = -\frac{\varepsilon}{\beta_1}, \quad (7)$$

即误差越大、斜率越小，达标时间的不确定度越大。据此，对每名孕妇以其插值达标时间  $T_i$  为基线，叠加正态扰动  $\varepsilon \sim N(0, \sigma_{\text{meas}})$  生成  $K$  个蒙特卡洛样本

$$\tilde{T}_i^{(k)} = T_i - \frac{\varepsilon_i^{(k)}}{\beta_1}, \quad k = 1, \dots, K, \quad (8)$$

再按固定 BMI 分组边界聚合，得到各组的达标比例曲线  $P_k(t)$  与达标时间分布，并以  $t_k^* = \min\{t : P_k(t) \geq 0.95\}$  作为“保证 95% 孕妇达标”的最佳时点。蒙特卡洛方法提供了一种将随机误差显式纳入决策的通用框架 [5]。

### 5.3.3 求解结果

取  $\sigma_{\text{meas}} = \sigma_e = 1.713\%$ ，各组 95% 达标的最佳时点与达标比例曲线分别见表 7 与图 8a。

**表 7 蒙特卡洛最佳时点 ( $\sigma_{\text{meas}} = 1.713\%$ , 95% 达标)**

| 分组 | BMI 区间       | 达标中位 (周) | 90% 达标周 | 95% 达标周 | 最佳时点 (周) |
|----|--------------|----------|---------|---------|----------|
| G1 | [20.7, 29.9] | 13.02    | 20.67   | 22.74   | 22.75    |
| G2 | [30.0, 31.6] | 12.92    | 20.16   | 22.24   | 22.25    |
| G3 | [31.6, 33.5] | 13.59    | 22.36   | 25.56   | 25.75    |
| G4 | [33.7, 46.9] | 13.96    | 22.52   | 25.29   | 25.50    |

对比问题二与问题三：问题三因采用更严格的 95% 达标准则并显式计入检测误差，最佳时点整体后移，但分组相对次序一致——低 BMI 组 (G1、G2) 最佳时点约 22.3–22.8 周，高 BMI 组 (G3、G4) 约 25.5–25.8 周。这进一步印证了“高 BMI 孕妇应推迟检测”的核心结论。

### 5.3.4 检测误差敏感性分析

改变检测误差标准差  $\sigma_{\text{meas}} \in \{0.5\%, 1.0\%, 1.713\%, 2.5\%\}$ ，重新计算各组最佳时点，结果见表 8 与图 9。




图 8 问题三蒙特卡洛达标比例与达标时间分布

表 8 检测误差敏感性：各组 95% 达标周

| 分组 | $\sigma = 0.5\%$ | $\sigma = 1.0\%$ | $\sigma = 1.713\%$ | $\sigma = 2.5\%$ |
|----|------------------|------------------|--------------------|------------------|
| G1 | 18.25            | 19.75            | 22.75              | 27.00            |
| G2 | 16.50            | 18.75            | 22.25              | 26.50            |
| G3 | 24.00            | 23.75            | 25.50              | 29.25            |
| G4 | 22.25            | 23.00            | 25.25              | 29.00            |

当检测误差标准差由 0.5% 增至 2.5%，各组最佳时点推迟 5–10 周，其中 G2 最敏感（推迟 10 周）。这定量说明了测序误差对时点决策的决定性影响：检测精度下降时，为保证 95% 的达标比例，必须显著推迟检测时点，代价是治疗窗口期缩短。因此，控制测序误差、提高检测稳定性是优化 NIPT 时点的重要途径。

## 5.4 问题四：女胎异常判定方法

### 5.4.1 数据与特征工程

问题四以女胎 21/18/13 号染色体非整倍体 (AB 列) 为判定标签 (异常记为 1、正常记为 0)，在剔除缺失后得到 604 例样本，其中异常 67 例 (11.1%)、正常 537 例，存在明显的类别不平衡。综合考虑 X 染色体及各染色体的 Z 值、GC 含量、原始/唯一比对读段数、比对比例、重复读段比例、BMI、年龄、孕周等，构造 21 个特征，并衍生 maxZ (三染色体最大 Z 值)、minZ、Z 极差与对数读段数等 4 个特征。




图 9 各组最佳 NIPT 时点（误差棒为检测误差敏感性）

#### 5.4.2 分类模型

采用 Logistic 回归 [6] 与随机森林 [7] 两类模型对比。Logistic 回归给出线性可解释的概率：

$$P(y = 1 | \mathbf{x}) = \sigma \left( \beta_0 + \sum_j \beta_j x_j \right), \quad \sigma(z) = \frac{1}{1 + e^{-z}}. \quad (9)$$

随机森林通过自助采样与随机特征选择构建大量决策树并投票集成，能捕捉特征间非线性与交互作用，且对类别不平衡更稳健。两类模型均采用 5 折分层交叉验证，并对少数类赋予更高的权重以缓解类别不平衡，以 ROC-AUC、PR-AUC 与 F1 为评价指标。

#### 5.4.3 结果分析

两类模型的交叉验证性能见表 9，ROC/PR 曲线与混淆矩阵见图 10a。

表 9 分类模型 5 折交叉验证性能

| 模型          | ROC-AUC       | PR-AUC        | F1            |
|-------------|---------------|---------------|---------------|
| Logistic 回归 | 0.557 ± 0.113 | 0.190 ± 0.074 | 0.193 ± 0.068 |
| 随机森林        | 0.781 ± 0.080 | 0.424 ± 0.099 | 0.382 ± 0.078 |

随机森林在全部指标上显著优于 Logistic 回归（AUC 0.781 vs 0.557）。随机森林混淆矩阵为：正常样本正确识别 523 例、误判 14 例（特异度 97.4%），异常样本正确识别 19 例、漏判 48 例（敏感度 28.4%）；Logistic 回归特异度仅 59.2%。图 10a 与表 9 共同

表明：在严重类别不平衡下，随机森林凭借非线性边界与集成优势，显著提升了女胎异常的判别能力。




图 10 问题四模型 ROC/PR 曲线与关键特征分布

图 11a 与图 11b 分别从混淆矩阵与多维雷达两个角度对比两类模型的判别能力。混淆矩阵直观显示随机森林把绝大多数正常样本判对（特异度 97.4%），误报仅 14 例；雷达图将 ROC-AUC、PR-AUC、特异度、敏感度、F1 五个指标叠加对比，随机森林的包络面积显著大于 Logistic 与“Z 值阈值”基线，尤其在特异度与 ROC-AUC 上优势明显。但两者在敏感度上均偏低，提示少数类（异常）的识别仍是薄弱环节。




图 11 问题四混淆矩阵与模型性能雷达

特征重要性（图 12）显示，判别女胎异常的前三个关键特征依次为 X 染色体浓度（重要性 0.179）、13 号染色体 GC 含量（0.086）、孕妇 BMI（0.073），而非 Z 值。结合图 10b：异常组与正常组在 maxZ 上差异不大，而 X 染色体浓度在两组间分布明显不同。这一发现具有临床意义——在女胎（无 Y 染色体可资判别）场景下，X 染色体浓度与测序质量指标（GC 含量）比单一 Z 值更具判别力，提示可据此设计更稳健的异常判定规则。




图 12 随机森林特征重要性 (Top 10)

#### 5.4.4 小结

问题四给出了一套完整、可解释的女胎异常判定方法：在类别不平衡下优先采用随机森林 (AUC 0.781、特异度 97.4%)，并识别出 X 染色体浓度与 13 号染色体 GC 含量为关键判别因子。该结果可为临床 NIPT 女胎异常筛查提供特征选择与模型选型的依据。

## 六、模型检验与分析

为验证本文构建模型的有效性与稳健性，从拟合优度、交叉验证与灵敏度三个层面进行检验。

### 6.1 拟合优度与显著性检验

问题一的回归模型以决定系数  $R^2$  与  $F$  检验评价拟合优度，其中多项式模型  $R^2 = 0.056$ 、 $F = 12.83$  ( $p = 3.9 \times 10^{-12}$ )，模型整体显著；混合效应模型中孕周固定效应  $z = 19.42$ 、BMI 效应  $z = -2.65$ ，均在 1% 水平显著。问题三的多因素混合效应中孕周效应  $p = 6.1 \times 10^{-84}$ 、BMI 效应  $p = 0.0075$ ，同样高度显著。各模型的残差基本满足零均值与同方差假设，残差分布见图 13，未见系统性偏差。




图 13 问题一回归模型残差诊断

## 6.2 交叉验证检验

问题四的分类模型采用 5 折分层交叉验证，避免单一划分带来的偏差。随机森林各折 ROC-AUC 为  $0.781 \pm 0.080$ ，波动较小，表明模型对数据划分稳健；Logistic 回归 AUC 为  $0.557 \pm 0.113$ ，波动较大且性能偏低。混淆矩阵进一步给出特异度 97.4%（随机森林），说明模型在“不误报正常胎儿”上表现优异，临床可接受度高。

## 6.3 灵敏度分析

本文重点考察了两个关键不确定源对结论的影响。

**(1) 阈值敏感性（问题二）。**对 4% 达标阈值施加  $\pm 0.3\%$  扰动，各组 90% 达标周变化见表 5。阈值每偏离 0.3%，最佳时点偏移约 1–3 周，最优时点对阈值不敏感，结论稳健。

**(2) 检测误差敏感性。**改变检测误差标准差  $\sigma_{\text{meas}} \in \{0.5\%, 1.0\%, 1.713\%, 2.5\%\}$ ，各组 95% 达标周变化见表 8。误差标准差由 0.5% 增至 2.5% 时，最佳时点最多推迟约 10 周（G2），表明检测误差是时点决策的关键敏感因素，控制测序误差至关重要。

综合来看，本文模型的拟合与显著性检验通过、分类模型交叉验证稳定、阈值与检测误差两类灵敏度分析量化了主要不确定源的影响范围，模型具有良好的稳健性与可解释性。

# 七、模型的评价

## 7.1 模型的优点

- **方法针对性强、层层递进：**针对数据纵向重复测量的结构，问题一引入混合效应模型，正确分离了个体内与个体间变异，揭示出被汇聚相关掩盖的真实规律（个体内斜率  $+0.313\%/周$ ）；问题二、三分别用决策树与蒙特卡洛完成分组与误差传播，问题四用随机森林处理类别不平衡，各问方法与其数据特征高度匹配。
- **统一口径、结果可比：**四个问题均以“Y 浓度  $\geq 4\%$  即达标”为统一判据，达标时间与最佳时点的定义贯穿一致，问题二与问题三的结果可横向对比、相互印证。
- **误差处理严谨：**显式区分了阈值误差（问题二）与测序误差（问题三），并给出误差传播的解析形式  $\delta T = -\varepsilon/\beta_1$  与蒙特卡洛仿真，量化了不确定源对时点决策的影响。
- **共线性诊断规范：**通过 VIF 诊断识别出 BMI、体重、身高的严重共线性，合理归并体型指标，避免了冗余变量对回归的干扰。

## 7.2 模型的缺点

- 达标时间存在大量左删失（81.3% 首次采血即达标），对“最早达标时间”的真实值只能给出上界，可能低估部分孕妇的实际达标时点，进而使最佳时点偏保守。
- 女胎异常判定中异常样本仅 67 例，类别不平衡下随机森林的敏感度（28.4%）仍偏低，漏判率较高，需更多异常样本或引入代价敏感学习进一步改善。
- 模型将检测误差简化为与协变量独立的正态噪声，实际测序误差可能与 GC 含量、读段深度等存在关联，该近似可能低估某些情况下的不确定度。

## 7.3 模型的改进

针对上述不足，可从三方面改进：其一，采用区间删失的生存分析方法（如 Kaplan-Meier 或区间删失回归）替代简单插值，更充分利用左删失信息估计达标时间；其二，对女胎异常判定引入 SMOTE 过采样、代价敏感随机森林或 XGBoost 等更强方法，并构造 SHAP 值做可解释性分析，在提升敏感度的同时保持可解释性；其三，将测序误差建模为随 GC 含量、读段深度变化的条件异方差模型，使误差传播更贴合实际。

## 7.4 模型的推广

本文的建模框架具有较好的普适性。首先，可将“达标时间 + 分组寻优 + 误差传播”的思路推广到其他染色体的非整倍体检测及其他基于游离 DNA 的检测（如产前亲子鉴定、肿瘤早筛），只需更换对应的阈值与生物标志物。其次，混合效应与蒙特卡洛方法适用于一切具有纵向重复测量与个体差异的医学检测时点优化问题。最后，所识别的 X 染色体浓度、GC 含量等判别特征，可为临床 NIPT 的质量控制与异常筛查提供直接的指标参考，助力构建更稳健、个体化的产前检测方案。

## AI 工具使用声明

本参赛队在竞赛过程中使用了 AI 工具，主要用于语言润色、代码调试与图表排版，详细使用情况见支撑材料。



## 参考文献

- [1] Chiu R W K, Chan K C A, Gao Yuan, et al. Noninvasive prenatal diagnosis of fetal chromosomal aneuploidy by massively parallel genomic sequencing of DNA in maternal plasma[J/OL]. Proceedings of the National Academy of Sciences, 2008, 105 (51) : 20458-20463. <http://dx.doi.org/10.1073/pnas.0810641105>.
- [2] Chen E Z, Chiu R W K, Sun Hao, et al. Noninvasive prenatal diagnosis of fetal trisomy 18 and trisomy 13 by maternal plasma DNA sequencing[J/OL]. PLoS ONE, 2011, 6 (7) : e21791. <http://dx.doi.org/10.1371/journal.pone.0021791>.
- [3] Wang E, Batey A, Struble C, et al. Gestational age and maternal weight effects on fetal cell-free DNA in maternal plasma[J/OL]. Prenatal Diagnosis, 2013, 33 (7) : 662-666. <http://dx.doi.org/10.1002/pd.4119>.
- [4] Breiman L, Friedman J H, Olshen R A, et al. Classification and regression trees[M/OL]. Routledge, 2017. <http://dx.doi.org/10.1201/9781315139470>.
- [5] Metropolis N, Ulam S. The monte carlo method[J/OL]. Journal of the American Statistical Association, 1949, 44 (247) : 335-341. <http://dx.doi.org/10.1080/01621459.1949.10483310>.
- [6] Hosmer D W, Lemeshow S. Applied logistic regression[M/OL]. Wiley, 2000. <http://dx.doi.org/10.1002/0471722146>.
- [7] Breiman L. Random forests[J/OL]. Machine Learning, 2001, 45 (1) : 5-32. <http://dx.doi.org/10.1023/a:1010933404324>.
- [8] Cserhati M. Calculation of fetal fraction for non-invasive prenatal testing[J/OL]. BioTech, 2021, 10 (3) : 17. <http://dx.doi.org/10.3390/biotech10030017>.
- [9] Benn P, Cuckle H. Theoretical performance of non-invasive prenatal testing for chromosome imbalances using counting of cell-free DNA fragments in maternal plasma: expected NIPT performance[J/OL]. Prenatal Diagnosis, 2014, 34 (8) : 778-783. <http://dx.doi.org/10.1002/pd.4366>.
- [10] Laird N M, Ware J H. Random-effects models for longitudinal data[J/OL]. Biometrics, 1982, 38 (4) : 963. <http://dx.doi.org/10.2307/2529876>.

## 附录

### 附录 A 主要数据说明

本文所用附件数据包含两个工作表：男胎检测数据（1082 条记录、267 名孕妇）与女胎检测数据（605 条记录、147 名孕妇）。数据字段说明见赛题附录 1； $Z$  值计算式  $Z = (X - \mu)/\sigma$  见赛题附录 2，其中  $X$  为目标染色体相对计数比例， $\mu$ 、 $\sigma$  分别为正常对照群体该比例的均值与标准差。

### 附录 B 程序代码清单

各问题的求解代码相互独立、可复现，运行环境为 Python 3.14 + pandas / numpy / scipy / statsmodels / scikit-learn / matplotlib / seaborn / plotly。

表 10 附件说明表

| 文件                     | 说明                       |
|------------------------|--------------------------|
| code/common.py         | 公共模块：数据加载、孕周解析、全局绘图样式    |
| code/q1_correlation.py | 问题 1：相关分析与三类回归模型         |
| code/q1_panel.py       | 问题 1：个体内斜率与混合效应模型        |
| code/q2_grouping.py    | 问题 2：BMI 决策树分段与最佳时点      |
| code/q3_montecarlo.py  | 问题 3：多因素混合效应与蒙特卡洛        |
| code/q4_classify.py    | 问题 4：Logistic 与随机森林异常判定  |
| code/fig_extra.py      | 高级补充图（Sankey/山脊/雷达/聚类热图） |
| texfile/figures/*.png  | 论文全部插图                   |
| AI 工具使用详情.pdf          | AI 工具名称、使用过程及人工核验说明      |

### 附录 C 关键结果汇总

为便于核验，将四个问题的核心结果汇总如下表。

表 11 各问题核心结果汇总

| 问题   | 核心结果                                                                                               |
|------|----------------------------------------------------------------------------------------------------|
| 问题 1 | $r_{\text{week}} = 0.126$ 、 $r_{\text{BMI}} = -0.151$ ；混合效应 $\beta_1 = +0.313\%/周$ 、 $ICC = 0.739$ |
| 问题 2 | 4 组 BMI 区间 $[20.7, 29.9]/[30.0, 31.6]/[31.6, 33.5]/[33.7, 46.9]$ ，最佳时点 15.7/13.9/15.6/19.0 周       |
| 问题 3 | 蒙特卡洛 95% 达标最佳时点 22.75/22.25/25.75/25.50 周；误差 $\sigma$ 增大使时点最多推迟 10 周                               |
| 问题 4 | 随机森林 AUC 0.781、特异度 97.4%、敏感度 28.4%；关键特征为 X 浓度与 13 号 GC 含量                                          |